

Cerinta 1

Clasa MRI_classification este un dataset personalizat pentru procesarea imaginilor de tip RMN. Se ocupa de încărcarea, transformarea și vizualizarea batchurilor de imagini. Funcționalitățile principale includ:

- Ajustarea luminozității pentru a evidenția detaliile.
- Filtrul Gaussian pentru reducerea zgomotului.
- CLAHE pentru îmbunătățirea contrastului.
- Normalizare pentru scalarea pixelilor într-un interval standard.

Cerinta 2



În urma splitului avem:

- Setul de antrenare are 2296 imagini.
- Setul de validare are 574 imagini.
- Setul de testare are 394 imagini.

Cerinta 3



Pentru început, am folosit niste bar ploturi și niste pie charturi pentru a observa distribuția tumorilor în seturile de date:

1. Pentru setul de antrenare avem următoarele:





Astfel, gasim informații despre echilibrul setului de date, arătând o distribuție relativ uniformă între tipurile de tumori, cu excepția categoriei „fără tumoare,” care este subreprezentată. Acest dezechilibru ar putea influența rezultatele unui model de învățare automată.

2. Pentru setul de testare avem următoarele:



Avem o reprezentare mai echilibrată între tipurile de tumori, deși categoria “pituitara” are o proporție mai mică comparativ cu celelalte tipuri

3. Pentru testul de validare avem:

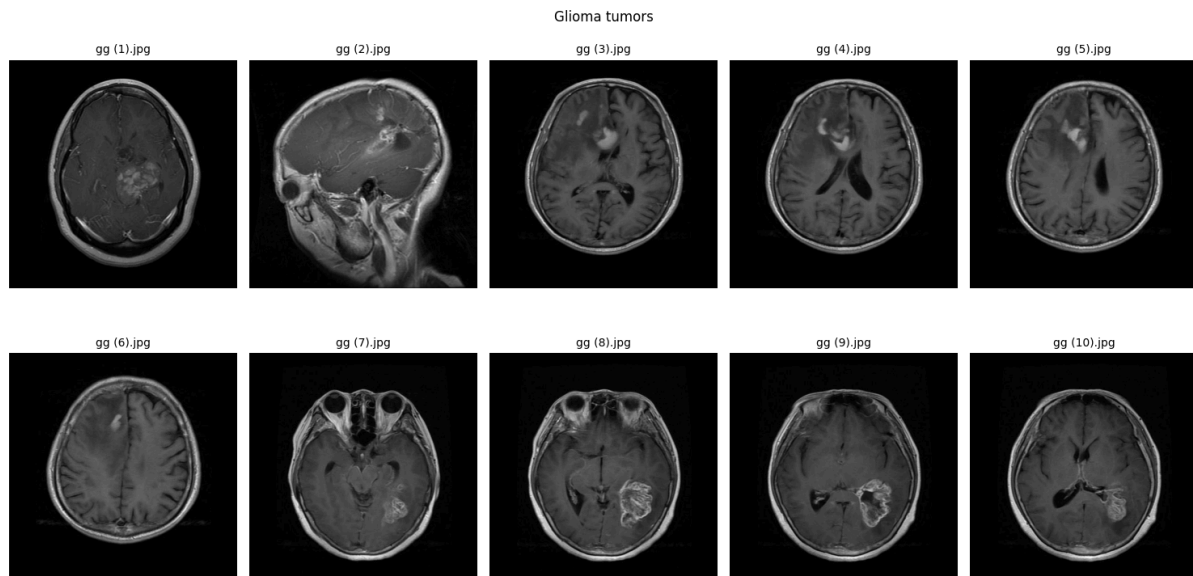


La fel ca la setul de antrenare, categoria „fără tumoare” este subreprezentată. Această distribuție poate influența performanța modelului de validare.

Cerinta 4

Aici, am extras seturi de 5/10 imagini din diferite categorii de tumori:


4.1 Tumorile de tip “glioma”:



Tumorile pot avea dimensiuni și forme diferite, unele fiind bine delimitate, iar altele cu margini mai difuze.


Tumorile gliomice pot varia semnificativ în ceea ce privește forma și dimensiunea, fiind mai dificil de diferențiat în comparație cu alte categorii

4.2 Tumorile de tip “meningioma”:




Tumorile meningioame pot varia în dimensiuni și densitate, dar de regulă sunt bine delimitate

4.3 Tumorile de tip "pituitary":



Din aceste imagini se observă diferențe în mărime, dar forma și localizarea tumorilor pituitare sunt destul de constante

4.4 Radiografiile fara tumori:



Imaginile fără tumori prezintă o consistență ridicată, ceea ce le face o categorie clară pentru modelul de clasificare.

Cerinta 5

În urma analizei setului de date și a transformărilor aplicate, am ajuns la următoarele concluzii:

1. Consistența dimensiunilor imaginilor: Toate imaginile au fost redimensionate la dimensiunea standard (256, 256), eliminând problema legată de dimensiunile inițiale.
2. Uniformitatea canalelor: Imaginile au fost convertite la format grayscale (dacă era necesar), pentru a standardiza reprezentarea lor.
3. Transformări aplicate: CLAHE și normalizarea au fost cele mai eficiente metode pentru îmbunătățirea clarității imaginilor, asigurând o vizibilitate mai bună a zonelor importante. Ajustarea luminozității și filtrul Gaussian au redus variațiile nedorite între imagini, dar au păstrat caracteristicile relevante.
4. Variabilitatea între clase: Clasele cu tumori (glioma, meningioma, pituitary) au o variabilitate mai mare internă în ceea ce privește forma, dimensiunea și poziționarea tumorilor. Clasa no tumor este mai consistentă, ceea ce poate duce la un dezechilibru în performanța modelului, existând posibilitatea ca modelul să detecteze mai bine absența tumorilor.
5. Impactul transformărilor: Transformările aplicate au redus zgomotul și au îmbunătățit contrastul, crescând astfel calitatea imaginilor pentru antrenare. Totuși, am eliminat transformările excesive, cum ar fi thresholdingul.


Cerinta 6

1. Adjustarea luminozității (Brightness Adjustment)


După ajustare, zonele întunecate devin mai vizibile, dar contrastul general rămâne scăzut. Am decis sa fac aceasta modificare pentru observarea detaliilor ascunse în zonele mai întunecate.

Original Images

gg (1).jpg




gg (2).jpg




Images after Brightness Adjustment


gg (1).jpg




gg (2).jpg




gg (3).jpg




gg (4).jpg



gg (3).jpg



gg (4).jpg



2. Filtrul Gaussian


Filtrul a estompat detalii mici, dar tumorile rămân vizibile ca mase generale. Zgomotul de fundal (mai ales în zonele fără tumori) este redus. Diminueaza detalii critice, cum ar fi margini subtile ale tumorilor, ceea ce este important pentru detecție precisă

3. CLAHE:


Contrastul este semnificativ îmbunătățit în regiunile tumorale, scoțând în evidență diferențele de textură dintre tumori și țesuturile normale. Zonele întunecate și luminoase sunt mai bine echilibrate, oferind o imagine mai clară

Images after Gaussian filter

gg (1).jpg




gg (2).jpg




Images after Clahe


gg (1).jpg




gg (2).jpg




gg (3).jpg




gg (4).jpg



gg (3).jpg



gg (4).jpg



4. Normalizare:


Intensitățile pixelilor sunt echilibrate, reducând diferențele între imagini. Tumorile rămân vizibile, dar contrastul general este mai redus comparativ cu CLAHE. Mai puțin benefic pentru acest tip de dataset, deoarece elimină informațiile despre textura și variațiile interne ale tumorilor.

5. Prag (Thresholding):


Transformarea binară evidențiază doar contururile și zonele foarte contrastante. Detaliile fine ale tumorilor sunt eliminate complet, păstrând doar structurile mari și clar delimitate. Tocmai din acest motiv, nu este benefic să aplicăm această transformare

Images after Normalization


gg (1).jpg




gg (2).jpg



gg (3).jpg



gg (4).jpg



Images after Thresholding

gg (1).jpg



gg (2).jpg



gg (3).jpg



gg (4).jpg



Cerinta 7

Am decis sa folosesc reseaua LeNet, din laborator, acesta fiind un model CNN simplu, folosit pentru clasificarea imaginilor. Are două straturi convoluționale cu pooling (AvgPool2d), urmate de trei straturi conectate (fc1, fc2, fc3) și activări ReLU.

Dimensiunile imaginilor sunt reduse prin pooling, iar datele sunt flattened înainte de straturile dense. Modelul necesită imagini de intrare compatibile cu dimensiunile specificate (ex. 256x256).

Acest script implementează antrenarea unui model de clasificare cu PyTorch, utilizând acuratețea și AUC pentru evaluare. Acesta calculează pierderea și ajustează parametrii prin backpropagation, modelul optim fiind salvat pe baza celui mai bun AUC.